PRML 作业 1 报告

黄欣儒 23376061

15928304723@163.com

摘要

本文基于 Data4Regression 数据集，系统研究了线性回归与非线性基函数扩展方法在回归预测任务中的表现。在线性模型部分，分别采用最小二乘法、梯度下降法和牛顿法对同一均方误差目标函数进行求解，并比较不同优化策略下模型的收敛特性与拟合效果。实验结果表明，三种线性方法均收敛到一致解，但整体预测误差较高，说明线性模型难以有效刻画该数据中的非线性结构。为提升模型表达能力，本文进一步引入基函数扩展方法，依次构建多项式模型、多项式与三角函数混合模型以及 RBF 结合 L_2正则化模型。结果表明，随着模型表达能力的增强，测试集均方误差由线性模型的约 0.595 依次降低至 0.463、0.333 和 0.250，其中最终模型相较线性基线下降约 57.9%。实验结果说明，基函数设计与正则化策略的合理结合能够显著提升模型对复杂非线性关系的刻画能力与泛化性能。

关键词： 线性回归；最小二乘法；梯度下降；牛顿法；基函数扩展；径向基函数；L_2 正则化

Abstract

This study investigates linear and nonlinear regression methods on the Data4Regression dataset. In the linear modeling stage, Least Squares, Gradient Descent, and Newton's Method are employed to estimate the parameters of the same linear regression model, and their convergence behavior and predictive performance are compared. Experimental results show that all three methods converge to essentially the same solution, while the overall prediction error remains relatively high, indicating that the linear model is insufficient to capture the nonlinear structure of the data.

To improve the expressive power of the model, basis function expansion is further introduced. Specifically, polynomial regression, polynomial-trigonometric mixed basis regression, and radial basis function (RBF) regression with L_2regularization are constructed and evaluated in sequence. The results show that the test mean squared error is gradually reduced from about 0.595 for the linear baseline to 0.463 for the polynomial model, 0.333 for the mixed basis model, and 0.250 for the RBF regularized model. Compared with the linear baseline, the final model achieves an error reduction of approximately 57.9%. These results demonstrate that an appropriate combination of basis function design and regularization can significantly improve the model's ability to fit complex nonlinear relationships while maintaining good generalization performance.

Keywords: linear regression; least squares; gradient descent; Newton's method; basis function expansion; radial basis function; L_2regularization

1 引言

回归分析是模式识别与机器学习中的基础问题，其目标是通过建立输入变量与输出变量之间的映射关系，实现对未知样本的预测[1]。在线性假设成立时，最小二乘法、梯度下降法和牛顿法等方法能够高效求解参数，并构成经典回归分析的基本框架；其中，最小二乘法提供解析解，梯度下降法和牛顿法则分别体现了一阶与二阶优化思想，这些方法在统计学习与数值优化中均具有重要地位。

然而，在实际问题中，数据关系往往并非严格线性。对于具有明显弯曲趋势、局部波动甚至更复杂局部结构的数据，简单线性模型通常会产生欠拟合。为增强模型表达能力，常见思路是在保持参数线性形式的前提下，引入基函数扩展方法，将输入映射到更高维特征空间。其中，多项式基函数可用于刻画整体非线性趋势；三角函数适于补充周期性或局部振荡结构；径向基函数（RBF）则由于其局部响应特性，被广泛用于复杂非线性函数逼近[2]。与此同时，随着基函数数量增加，模型复杂度上升，过拟合风险也随之增强，因此需要结合 L_2正则化等方法控制模型复杂度并提高泛化性能[3]。

基于上述背景，本文首先以线性模型为基线，比较最小二乘法、梯度下降法和牛顿法在当前数据集上的表现；随后引入多项式、多项式与三角函数混合基函数以及 RBF+L_2 正则化模型，逐步提升模型的非线性表达能力，并对不同方法的训练误差、测试误差及拟合效果进行系统分析。

2 方法

基于 Data4Regression 数据集，本文采用最小二乘法、梯度下降法与牛顿法建立线性回归模型，并通过计算训练与测试误差对其性能进行评估。鉴于所给数据集为非线性数据，而线性模型在非线性数据上的表达能力受限，本文进一步引入基函数扩展方法，通过构造多项式基函数及多项式与三角函数的混合基函数模型，以增强对数据全局趋势与局部变化的刻画能力。在此基础上，本文结合径向基函数与 L_2正则化构建回归模型进行预测，并对各模型的性能进行了比较与分析。

2.1 线性模型的建立与求解

2.1.1 线性模型的建立

为刻画输入与输出之间的关系，本文建立一维线性回归模型

$$\hat{y} = w_0 + w_1 x \tag{1}$$

其中，x 为输入变量，w_0 为偏置项，w_1 为回归系数，$\hat{y}$ 为模型预测值。对于包含 n 个样本的数据集，上式可用矩阵形式表示

$$\hat{\mathbf{y}} = X\mathbf{w} \tag{2}$$

其中

$$X = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}, \hat{\mathbf{y}} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}$$

在线性模型中，我们希望找到最优 $\mathbf{w}$ ，使预测值与真实值误差尽可能小。为量化该误差，本文采用均方误差（Mean Squared Error, MSE）作为损失函数：

$$J(\mathbf{w}) = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2 \tag{3}$$

其矩阵形式为

$$J(\mathbf{w}) = \frac{1}{n} \| \mathbf{y} - X\mathbf{w} \|_2^2 \tag{4}$$

该目标函数是关于 $\mathbf{w}$ 的凸二次函数，因此可以通过解析方法或迭代优化方法进行求解。本文根据要求一，分别采用最小二乘法、梯度下降法和牛顿法对该线性模型进行参数估计。

2.1.2 最小二乘法

最小二乘法[4]（Least Squares, LS）是求解线性回归问题的经典方法，该方法通过最小化残差平方和来求解模型参数。对于 2.1.1 所述线性模型，最优化问题可表示为

$$\mathbf{w}^* = \arg\min_{\mathbf{w}} \| \mathbf{y} - X \|_2^2 \tag{5}$$

目标函数对 $\mathbf{w}$ 求导，令梯度为零，可得

$$\frac{\partial J(\mathbf{w})}{\partial \mathbf{w}} = -2X^T(\mathbf{y} - X\mathbf{w}) = 0 \tag{6}$$

整理后可得

$$X^T X\mathbf{w} = X^T\mathbf{y} \tag{7}$$

当矩阵 $X^T X$可逆时，线性模型的最小二乘解为

$$\mathbf{w} = (X^T X)^{-1} X^T \mathbf{y} \tag{8}$$

2.1.3 梯度下降法

梯度下降法[5]（Gradient Descent, GD）基于一阶导数信息进行迭代优化，以最小化均方误差损失函数，适用于可微目标函数。对公式(4)损失函数求梯度，有

$$\nabla J(\mathbf{w}) = \frac{2}{n} X^T (X\mathbf{w} - \mathbf{y}) \tag{9}$$

根据当前参数位置处的梯度方向，对参数进行迭代更新

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla J\left(\mathbf{w}^{(t)}\right) \tag{10}$$

其中，η 为学习率，用于控制每一步更新的幅度。将梯度表达式代入上式，可得

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \frac{2}{n} X^T \left(X\mathbf{w}^{(t)} - \mathbf{y}\right) \tag{11}$$

2.1.4 牛顿法

牛顿法[6]（Newton Method）利用二阶导数实现参数优化。与梯度下降法仅依赖一阶梯度不同，牛顿法同时利用梯度和 Hessian 矩阵对目标函数进行局部二次近似，从而实现更快的收敛。公式（9）损失函数梯度对应的 Hessian 矩阵为

$$H(\mathbf{w}) = \frac{2}{n} X^T X \tag{12}$$

由于在线性回归问题中，损失函数关于 $\mathbf{w}$ 是严格的二次函数，因此 Hessian 矩阵为常数矩阵，不依赖于参数本身。牛顿法的更新公式为

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - H^{-1} \nabla J\left(\mathbf{w}^{(t)}\right) \tag{13}$$

将上述梯度与 Hessian 代入可得

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \left(\frac{2}{n} X^T X\right)^{-1} \left(\frac{2}{n} X^T \left(X\mathbf{w}^{(t)} - \mathbf{y}\right)\right) \tag{14}$$

2.1.5 实验结果

从方法原理分析，最小二乘法能够直接给出闭式解，计算简单且结果稳定；梯度下降法通过迭代逐步逼近最优解，具有良好的扩展性，但收敛速度依赖于学习率；牛顿法利用二阶导数进行更新，如图 1 所示，牛顿法在本文数据下能快速收敛至最优解。

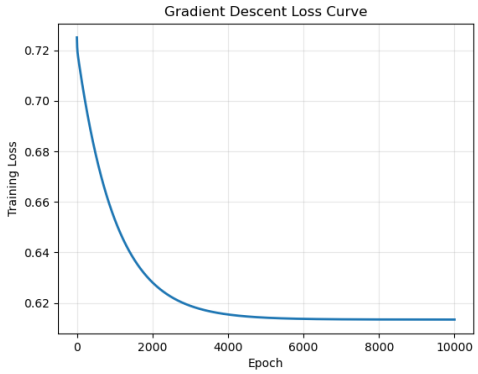

牛顿法-训练集

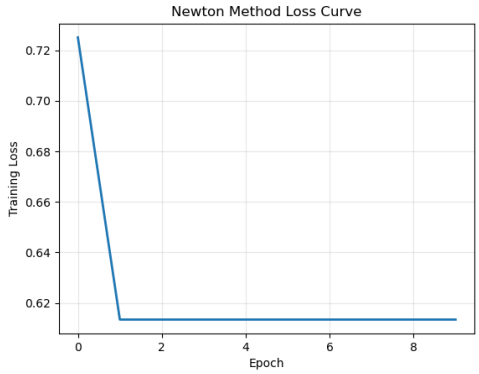

牛顿法-测试集

图 1 梯度下降与牛顿法损失曲线对比

从表 1 实验结果数据分析，三种方法得到的参数和误差基本一致，互为印证，说明均已达到最优解。结合图 2 拟合结果可以看出，三种方法得到的回归直线基本重合，但整体误差较高，且训练集误差与测试集误差差异较小。这表明线性模型在该数据集上存在明显欠拟合现象，难以刻画数据中的非线性变化趋势。因此，有必要引入非线性模型以进一步提高预测精度。

表 1 线性模型实验数据

方法	参数$\boldsymbol{w} = [w_0 \quad w_1]^T$	训练集误差	测试集误差
最小二乘法	$[-0.6487467 \quad 0.10894739]^T$	0.6134024281450052	0.5950433861467296
梯度下降法	$[-0.64420905 \quad 0.10826511]^T$	0.6134076541666258	0.594850134262443
牛顿法	$[-0.6487467 \quad 0.10894739]^T$	0.613402428145005	0.5950433861467296

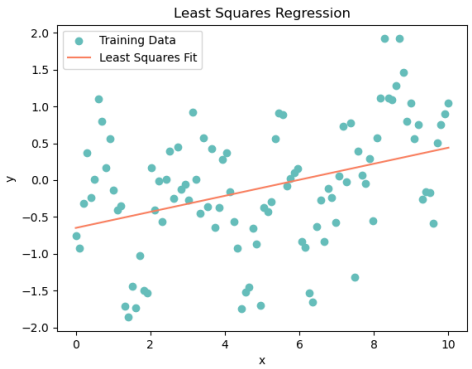

最小二乘-训练集

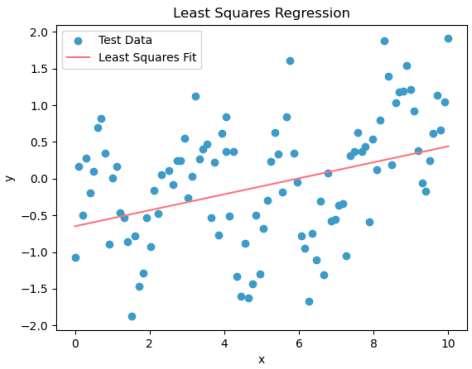

最小二乘-测试集

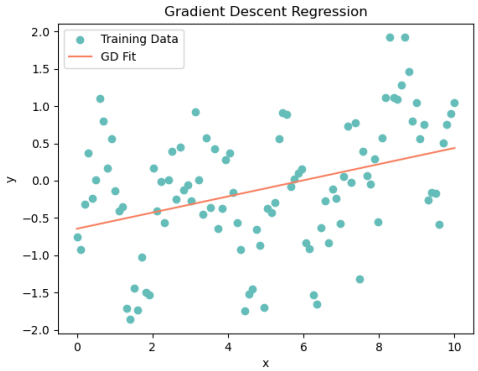

梯度下降-训练集

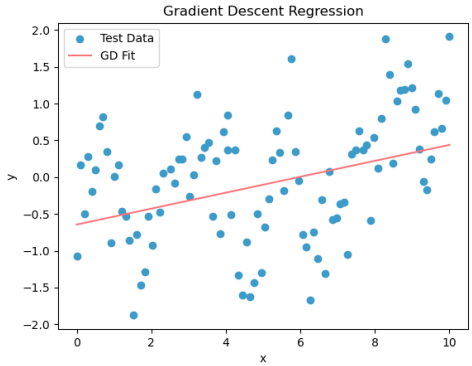

梯度下降-测试集

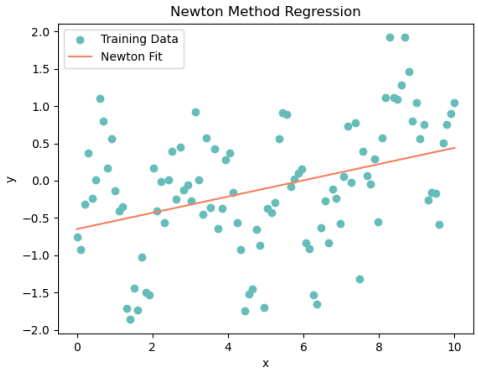

牛顿法-训练集

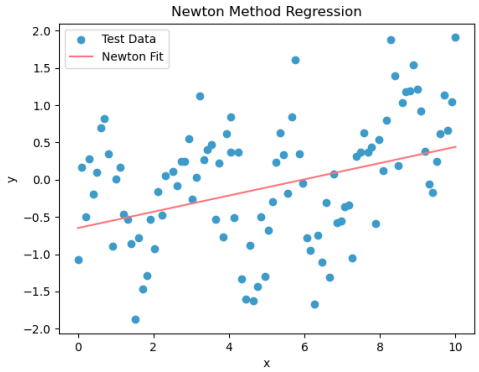

牛顿法-测试集

图 2 线性模型实验拟合结果

2.2 非线性模型与基函数扩展

2.2.1 基函数扩展

由 2.1 节实验结果可知，线性模型难以刻画非线性关系，因此在当前数据集上存在明显的欠拟合现象。为提高模型的拟合能力，本文引入基函数扩展方法，通过对原始输入变量进行非线性变换，将其映射到更高维特征空间，从而在保持模型对参数线性形式的同时，实现对其非线性关系的建模。

具体而言，设原始输入为 x，通过一组非线性基函数 $\{\phi_j(x)\}_{j=1}^{M}$对其进行映射，可得到新的特征表示：

$$\boldsymbol{\phi}(x) = [\phi_1(x), \phi_2(x), \dots, \phi_M(x)]^T \tag{15}$$

在该特征空间中，回归模型可表示为：

$$\hat{\mathbf{y}} = \Phi\mathbf{w} \tag{16}$$

其中 Φ为由基函数构造的设计矩阵，其第 i行为 $\boldsymbol{\phi}(x_i)^T$。尽管模型在输入空间中是非

线性的，但其对参数 $\mathbf{w}$仍保持线性，因此仍可采用最小二乘法或梯度下降等方法对进行求解。由于不同类型的基函数具有不同的函数表达能力，为提升模型性能，合理的基函数构建至关重要。其中，多项式基函数主要用于刻画数据的整体变化趋势，三角函数适用于描述周期性或局部波动结构，而径向基函数则具有良好的局部响应特性，能够对复杂非线性关系进行灵活建模。

2.2.2 多项式模型

多项式基函数是基本的非线性建模方法，因此本文先采用多项式基函数对数据进行初步建模[7]。对于输入变量 x，构造如下多项式基函数

$$\boldsymbol{\phi}(x) = [1, x, x^2, \dots, x^M]^T \tag{17}$$

并在该特征空间中采用最小二乘法对回归模型进行线性回归求解，从而实现对非线性关系的建模。

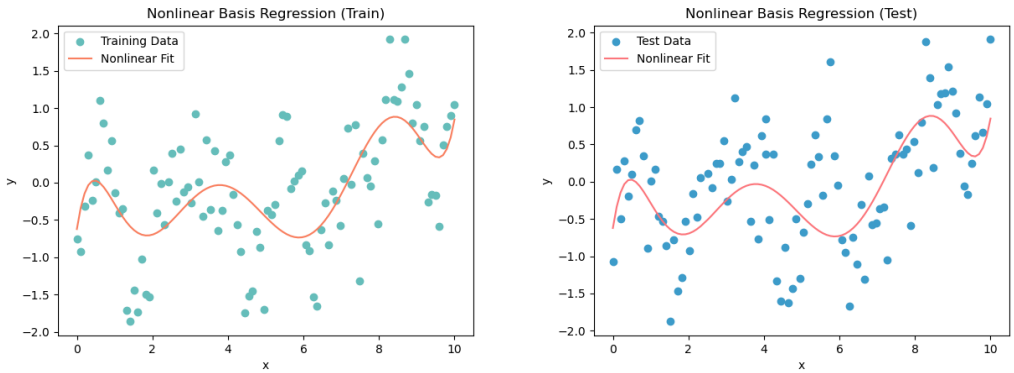

图 3 多项式基函数拟合结果

实验结果表明，相较于线性模型，多项式模型能够显著降低误差，其测试集均方误差从约 0.595 降低至约 0.463，说明引入多项式基函数能够有效增强模型对整体非线性趋势的刻画能力，从而显著缓解欠拟合问题。然而，多项式基函数属于全局基函数，其对局部波动的刻画能力有限，因此模型误差仍然较高。为进一步提升模型性能，有必要引入能够描述局部变化或周期性结构的基函数。

2.2.3 多项式与三角函数混合模型

针对多项式模型局部表达能力不足的问题，本文在其基础上引入三角函数构建混合基函数模型。三角函数具有良好的周期性与局部波动刻画能力，因此可用于补充多项式模型对局部结构的表达。具体而言，构造如下基函数

$$\boldsymbol{\phi}(x) = [1, x, x^2, \dots, x^M, \sin(x), \cos(x), \sin(2x), \cos(2x), \dots, \sin(Nx), \cos(Nx)]^T \tag{18}$$

并采用最小二乘法对回归模型进行线性回归求解。

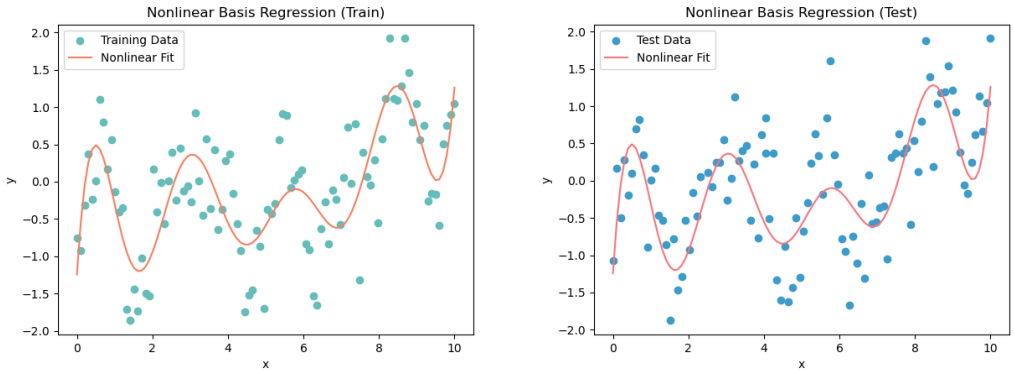

图 4 多项式与三角函数基函数拟合结果

实验结果表明，引入三角函数后，模型测试集均方误差进一步降低至约 0.333，相较于仅使用多项式模型有明显提升。这说明三角函数能够有效增强模型对局部波动的刻画能力，从而提高整体拟合效果。然而，该模型仍主要依赖全局基函数，其对复杂非线性结构的刻画能力仍然有限，因此仍存在进一步优化空间。

2.2.4 RBF 基函数与正则化模型

为进一步提升模型对复杂非线性关系的表达能力，本文引入径向基函数[2]（Radial Basis Function, RBF）进行建模，其形式为：

$$\phi_j(x) = \exp\left(-\frac{(x-c_j)^2}{2\sigma^2}\right) \tag{19}$$

其中 c_j为基函数中心，σ 控制函数的宽度。基于该基函数构造的模型能够在不同区域自适应调整拟合形状，从而更灵活地刻画复杂非线性关系。

然而，仅使用基函数时，模型在训练集与测试集上的误差存在较大差异。随着基函数数量增加，模型复杂度提升，易产生过拟合。为此，在模型中引入 L_2正则化项[3]，对参数进行约束

$$\min_{\mathbf{w}} \| \mathbf{y} - \Phi\mathbf{w} \|^2 + \lambda \| \mathbf{w} \|^2 \tag{20}$$

其解析解为：

$$\mathbf{w} = (\Phi^T\Phi + \lambda I)^{-1}\Phi^T\mathbf{y} \tag{21}$$

其中 λ为正则化系数，用于控制模型复杂度。通过对基函数数量、宽度参数 σ以及正则化系数 λ进行遍历搜索，得到最优参数组合——基函数数量为 20、$\sigma = 0.25$、$\lambda = 0.1$。

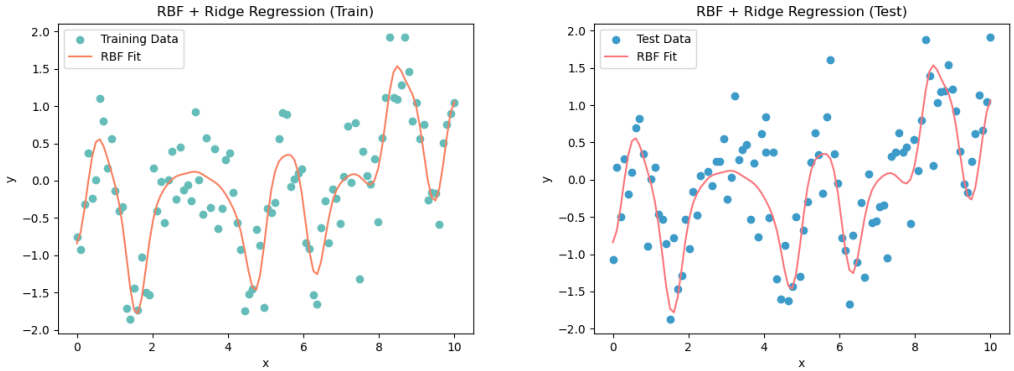

图 5 RBF 基函数与正则化模型拟合结果

实验结果表明，该模型在测试集上的均方误差降低至约 0.250，显著优于前述方法，说明 RBF 结合正则化能够在提升模型表达能力的同时有效抑制过拟合，从而获得更好的泛化性能。

2.2.5 结果与分析

多项式基函数能够有效刻画数据的整体非线性趋势，相较于线性模型显著降低了误差；在此基础上，引入三角函数进一步增强了模型对局部波动结构的表达能力，使模型性能得到进一步改善。然而，这两类方法均属于全局基函数，对复杂非线性关系的刻画仍然有限。为此，本文进一步引入具有局部响应特性的径向基函数进行建模，并结合 L_2 正则化以控制模型复杂度。通过对关键参数进行遍历搜索，最终获得了在训练误差与泛化性能之间较为平衡的模型。

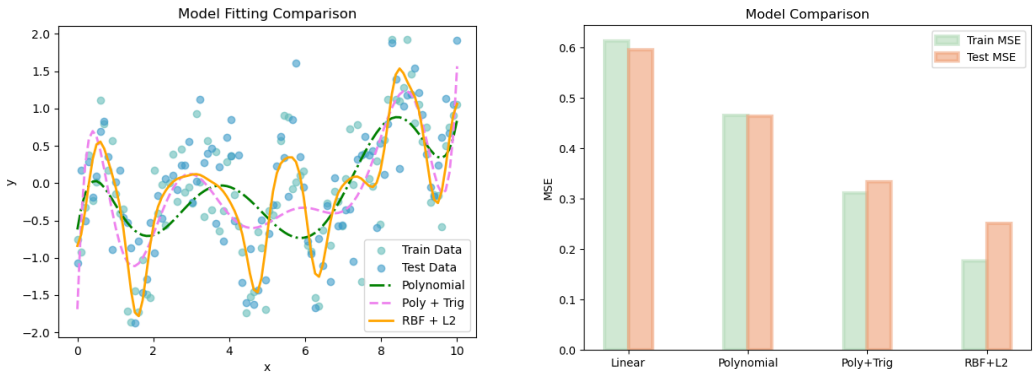

图 6 非线性模型拟合与误差对比

如图 6、表 2，实验结果表明，模型性能随着基函数设计的逐步改进而持续提升，RBF 结合正则化方法在测试集上取得了最优表现，说明该方法能够在增强模型表达能力的同时有效抑制过拟合。

表 2 非线性模型实验数据

方法	训练集误差	测试集误差
多项式模型	0.4650700553832805	0.46309455659645704
多项式与三角函数混合模型	0.31119942188135996	0.33297993674554255
RBF 基函数与正则化模型	0.17637779756796085	0.2503367744944006

3 结论

本文围绕 Data4Regression 数据集，分别从线性建模与非线性建模两个层面开展了回归分析。在线性模型部分，最小二乘法、梯度下降法和牛顿法虽然在求解策略上不同，但最终均收敛到一致解，测试集误差约为 0.595，说明三种方法在当前问题上都能够有效求得线性模型最优参数，但模型整体仍存在明显欠拟合。

在非线性模型部分，本文按照增强基函数表达能力的思路逐步改进模型。首先，多项式模型将测试集均方误差由 0.595 降低至 0.463，下降约 22.2%；随后，引入三角函数后，测试误差进一步降低至 0.333，相较多项式模型再下降约 28.1%，相较线性模型累计下降约 44.0%；最后，通过引入 RBF 基函数并结合 L_2正则化，对基函数数量、宽度参数和正则化系数进行遍历搜索，得到测试集均方误差 0.250 的最优结果，相较线性模型累计下降约 57.9%，相较混合基函数模型进一步下降约 24.8%。

总体而言，实验结果表明，随着模型从线性形式逐步过渡到多项式、混合基函数以及 RBF+L_2 正则化模型，模型对非线性关系的刻画能力不断增强，预测性能持续提升。其中，RBF 结合正则化的方法在表达能力与泛化性能之间取得了较优平衡，是本文效果最好的回归模型。

参考文献

[1] “Pattern Recognition and Machine Learning | Springer Nature Link.” Accessed: Mar. 27, 2026. [Online]. Available: https://link.springer.com/in/book/9780387310732

[2] J. Park and I. W. Sandberg, “Universal Approximation Using Radial-Basis-Function Networks,” *Neural Comput.*, vol. 3, no. 2, pp. 246–257, Jun. 1991, doi: 10.1162/neco.1991.3.2.246.

[3] A. E. Hoerl and R. W. Kennard, “Ridge Regression: Biased Estimation for Nonorthogonal Problems,” *Technometrics*, vol. 12, no. 1, pp. 55–67, Feb. 1970, doi: 10.1080/00401706.1970.10488634.

[4] “[1] Parameter estimation by least-squares methods,” in *Methods in Enzymology*, vol. 210, Academic Press, 1992, pp. 1–37. doi: 10.1016/0076-6879(92)10003-V.

[5] S. Ruder, “An overview of gradient descent optimization algorithms,” Jun. 15, 2017, *arXiv*: arXiv:1609.04747. doi: 10.48550/arXiv.1609.04747.

[6] B. T. Polyak, “Newton’s method and its use in optimization,” *Eur. J. Oper. Res.*, vol. 181, no. 3, pp. 1086–1096, Sep. 2007, doi: 10.1016/j.ejor.2005.06.076.

[7] A. Dean, D. Voss, and D. Draguljić, *Design and Analysis of Experiments*. in Springer Texts in Statistics. Cham: Springer International Publishing, 2017. doi: 10.1007/978-3-319-52250-0.