

PRML 作业 2 报告

基于三维双月牙数据的非线性分类方法比较与分析

黄欣儒 23376061

15928304723@163.com

摘要

针对三维非线性二分类问题，本文系统比较了决策树（Decision Tree）、AdaBoost 集成决策树以及支持向量机（Support Vector Machine, SVM）在不同模型结构和参数设置下的分类性能。实验数据采用已知程序生成的三维双月牙数据集，两类样本由具有镜像、平移和符号翻转关系的三维参数曲线叠加高斯噪声构成，因而具有明显的非线性流形结构和一定程度的类别交叠。本文从 Accuracy、Precision、Recall、F1-score 以及混淆矩阵等多个角度对模型进行系统评估，并结合二维切片决策边界图和错分点高亮图分析模型性能差异的来源。实验结果表明，单棵决策树随着最大深度增加性能稳步提升，最优情况下 Accuracy 达到 0.9500；AdaBoost + Decision Tree 在基学习器深度为 5 或 7 时表现最优，Accuracy 达到 0.9700；在四种 SVM 核函数中，RBF 核取得全局最佳结果，Accuracy 和 F1-score 分别达到 0.9720 和 0.9721，而线性核和 Sigmoid 核表现明显较差。研究表明，对于具有局部弯曲边界的三维非线性数据，具备局部平滑建模能力的分类器更能有效捕获类别结构，其中 SVM_RBF 在本实验中表现最佳，AdaBoost + Decision Tree 也显示出较好的性能。

关键词：模式识别；非线性分类；决策树；AdaBoost；支持向量机；RBF 核

Abstract

This paper presents a systematic comparison of classification methods for a three-dimensional nonlinear binary classification task. Decision Tree, AdaBoost with Decision Trees, and Support Vector Machines (SVMs) with different kernel functions are investigated under a unified experimental setting. The dataset is synthetically generated as a 3D double-moons structure, where the two classes are constructed from mirrored, shifted, and sign-flipped parametric curves with additional Gaussian noise. As a result, the data exhibit strong nonlinear manifold characteristics and partial class overlap. The models are evaluated using Accuracy, Precision, Recall, F1-score, and confusion matrices. In addition, decision boundary slice visualization and misclassified-point highlighting are employed to analyze the source of performance differences. Experimental results show that the performance of a single Decision Tree improves steadily as the maximum depth increases, reaching an Accuracy of 0.9500 at the best setting. AdaBoost with Decision Trees achieves its best performance when the base learner depth is 5 or 7, with an Accuracy of 0.9700. Among the four SVM kernels, the RBF kernel obtains the best overall result, with Accuracy and F1-score of 0.9720 and 0.9721, respectively, while the linear and sigmoid kernels perform significantly worse. These findings indicate that, for 3D nonlinear data with locally curved decision boundaries, classifiers with local smooth nonlinear modeling capability are more effective in capturing the underlying class structure. In this study, SVM with the RBF kernel achieves the best overall performance, while AdaBoost with Decision Trees also demonstrates strong competitiveness. The results highlight the importance of the match between data geometry and model inductive bias, and provide useful guidance for model selection in similar nonlinear classification tasks.

Keywords: pattern recognition; nonlinear classification; decision tree; AdaBoost; support vector machine; RBF kernel

1 引言

分类问题是模式识别与机器学习中的核心任务之一^[1]。对于实际数据而言，类别边界往往并不是简单的线性超平面，而是具有弯曲、交叠和噪声扰动等非线性特征。因此，针对非线性数据选择合适的分类模型，是提高识别性能的重要问题。

本文以三维双月牙二分类数据为研究对象，比较了单棵决策树、AdaBoost 集成决策树以及四种核函数支持向量机的分类性能。该数据具有明显的三维非线性流形结构，并叠加一定高斯噪声，因此能够较好地反映不同模型对复杂边界的建模能力。实验结果表明，单棵决策树随着最大深度增加性能逐步提升，AdaBoost 能够在树模型基础上进一步提高分类效果，而 SVM 中不同核函数之间存在显著差异，其中 RBF 核表现最佳，Accuracy 和 F1-score 分别达到 0.9720 和 0.9721。

本文通过统一实验设置，从分类指标、混淆矩阵、决策边界形态和错分样本分布等角度，分析不同方法在三维非线性分类任务中的适用性，并说明数据几何结构与模型选择之间的关系。

2 方法

2.1 问题定义与数据构造

本文研究一个三维空间中的二分类问题。设输入样本记为 $\mathbf{x} \in \mathbb{R}^3$ ，类别标签记为 $y \in \{0,1\}$ 。为系统比较不同分类器在非线形几何结构上的建模能力，本文采用程序化方式构造两类三维“月牙”形数据。具体而言，首先在参数区间 $t \in [0, 2\pi]$ 上进行等间隔采样，并定义第一类样本的无噪声轨迹为

$$\mathbf{s}_0(t) = \begin{bmatrix} 1.5\cos t \\ \sin t \\ \sin 2t \end{bmatrix},$$

第二类样本则由第一类样本经过镜像、翻转与平移变换得到：

$$\mathbf{s}_1(t) = \begin{bmatrix} -1.5\cos t \\ \sin t - 1 \\ -\sin 2t \end{bmatrix}.$$

为增强任务难度并模拟实际观测误差，在每个样本上进一步叠加独立同分布

的高斯噪声

$$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_3),$$

其中 $\sigma = 0.2$ 。因此，两类样本可分别表示为

$$\mathbf{x}_i^{(0)} = \mathbf{s}_0(t_i) + \boldsymbol{\varepsilon}_i, \mathbf{x}_i^{(1)} = \mathbf{s}_1(t_i) + \boldsymbol{\varepsilon}_i.$$

按照这一生成机制，本文构造训练集 1000 个样本，其中两类各 500 个；并使用不同随机种子再次生成与训练集同分布的测试集 500 个样本，其中两类各 250 个。




图 1 数据集三维立体与投影图

如图 1 对数据进行可视化处理可知，上述数据并不满足简单线性可分假设。两类样本在三维空间中呈现相互缠绕的非线性流形结构，并伴有局部噪声扰动。基于该数据特性，本文选取 Decision Trees、AdaBoost + Decision Trees、以及四类不同核函数的 SVM 作为比较对象，以分析不同模型结构对该类非线性任务的适配性。

2.2 Decision Trees

决策树通过递归地对特征空间进行划分来完成分类^[2]。设某一结点对应的样本集合为 D ，其类别分布中第 k 类的经验概率记为

$$p_k(D) = \frac{1}{|D|} \sum_{\mathbf{x}_i \in D} \mathbf{1}(y_i = k),$$

其中 $\mathbf{1}(\cdot)$ 为示性函数。本文采用基尼不纯度作为结点纯度度量，其定义为

$$G(D) = 1 - \sum_{k=0}^1 p_k(D)^2.$$

当结点中的样本全部属于同一类别时， $G(D) = 0$ ；当类别分布越均匀时， $G(D)$ 越大。对任意候选划分 $\theta = (j, s)$ ，其中 j 表示划分特征维度， s 表示划分阈值，样本集合 D 被分为左右两个子集

$$D_L(\theta) = \{\mathbf{x} \in D \mid x_j \leq s\}, D_R(\theta) = \{\mathbf{x} \in D \mid x_j > s\}.$$

对应的加权划分后不纯度为

$$G_{\text{split}}(D, \theta) = \frac{|D_L(\theta)|}{|D|} G(D_L(\theta)) + \frac{|D_R(\theta)|}{|D|} G(D_R(\theta)).$$

训练过程中，决策树在每个结点选择使得划分后不纯度最小、等价地使不纯度下降最大的一组参数，即

$$\theta^* = \arg \min_{\theta} G_{\text{split}}(D, \theta) = \arg \max_{\theta} [G(D) - G_{\text{split}}(D, \theta)].$$

通过不断递归执行上述过程，特征空间被划分为若干互不重叠的叶结点区域 $\{R_l\}_{l=1}^L$ ，最终分类函数可写为

$$f_{\text{DT}}(\mathbf{x}) = \sum_{l=1}^L c_l \mathbf{1}(\mathbf{x} \in R_l),$$

其中 c_l 表示第 l 个叶结点对应的多数类标签。本文实现中采用 gini 作为划分准则，并将最大树深 d 作为主要复杂度控制参数。随着 d 增大，模型能够拟合更复杂的非线性边界，但也更容易发生过拟合，因此本文进一步比较了不同深度下的性能变化。

决策树的优势在于其对特征缩放不敏感，且能够以分段轴对齐的方式近似复杂判别边界。但是这种局部贪心划分方式也决定了其表达的边界通常呈现明显的块状或阶梯状形态。当样本真实决策边界较为平滑、弯曲且跨越多个局部区域时，单棵决策树往往需要依赖更深层级才能获得足够拟合能力，因此其常作为基准模型用以初步尝试^[2-3]。

2.3 AdaBoost + Decision Trees

为了提升单棵决策树对复杂边界的刻画能力，本文进一步采用 AdaBoost 对

决策树进行集成。AdaBoost 的核心思想是通过迭代训练一系列弱分类器，并根据前一轮分类错误情况动态调整样本权重，使后续分类器更加关注难分类样本^[4]。为便于理论推导，本文将类别标签从 $\{0, 1\}$ 重新映射为 $\{-1, +1\}$ 。设训练集为 $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$ ，初始样本权重为

$$w_i^{(1)} = \frac{1}{N}, i = 1, 2, \dots, N.$$

在第 m 轮迭代中，使用当前权重分布 $w_i^{(m)}$ 训练一个弱分类器 $h_m(\mathbf{x}) \in \{-1, +1\}$ ，其加权分类误差定义为

$$\varepsilon_m = \sum_{i=1}^N w_i^{(m)} \mathbf{1}(h_m(\mathbf{x}_i) \neq y_i).$$

随后，根据弱分类器误差计算其组合系数

$$\alpha_m = \frac{1}{2} \ln \frac{1 - \varepsilon_m}{\varepsilon_m}.$$

若考虑学习率 η ，则可将其写为 $\eta \alpha_m$ ，以控制每一轮弱分类器对最终模型的贡献强度。第 m 轮结束后，样本权重更新为

$$w_i^{(m+1)} = \frac{w_i^{(m)} \exp(-\alpha_m y_i h_m(\mathbf{x}_i))}{Z_m},$$

其中 Z_m 为归一化常数，满足 $\sum_{i=1}^N w_i^{(m+1)} = 1$ 。该式表明：若样本被正确分类，则 $y_i h_m(\mathbf{x}_i) = 1$ ，其权重会减小；若被错误分类，则 $y_i h_m(\mathbf{x}_i) = -1$ ，其权重会增大。经过 M 轮迭代后，AdaBoost 的最终判别函数写为

$$F(\mathbf{x}) = \sum_{m=1}^M \alpha_m h_m(\mathbf{x}), H(\mathbf{x}) = \text{sign}(F(\mathbf{x})).$$

本文以决策树作为基学习器，并设置集成规模 $M = 100$ ，学习率为 1.0。通过改变基学习器的最大深度，可以控制单个弱分类器的表达能力，从而研究弱学习器复杂度与集成性能之间的关系。

与单棵决策树相比，AdaBoost 的优势在于它不是依赖单次划分形成完整判别结构，而是通过多个分类器的加权叠加逐步修正前序误差^[4]。因此，即使单个基学习器的边界较为粗糙，多个弱分类器叠加后仍能够逼近更复杂、更精细的非线性决策边界^[5]。对于本文所研究的三维带噪非线性月牙数据，这种逐步关注难样本的机制预期能够显著改善单棵树在边界区域的判别能力。

2.4 支持向量机及其多核函数建模

支持向量机通过在高维特征空间中构造最大间隔超平面完成分类^[6]。考虑映射 $\phi: \mathbb{R}^3 \rightarrow \mathcal{H}$ ，其中 $\mathcal{H}$ 为某个高维 Hilbert 空间，则软间隔 SVM 的原始优化问题可写为

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \xi_i$$

$$\text{s.t. } y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i, \xi_i \geq 0, i = 1, \dots, N.$$

其中， $\mathbf{w}$ 和 b 分别表示分离超平面的法向量与偏置项， ξ_i 为松弛变量， $C > 0$ 为惩罚参数，用于平衡间隔最大化与训练误差最小化之间的关系。通过拉格朗日对偶变换，上式可进一步写为

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

$$\text{s.t. } 0 \leq \alpha_i \leq C, \sum_{i=1}^N \alpha_i y_i = 0,$$

其中

$$K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

为核函数。由此，分类决策函数可表示为

$$f_{\text{SVM}}(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^N \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b \right).$$

该表达式说明，SVM 的非线性建模能力并不直接来自显式高维映射，而是来自核函数对样本相似性的定义方式。

由于核函数尤其是距离型核函数对特征尺度较为敏感，本文在所有 SVM 模型前均引入标准化预处理。对第 j 维特征，设训练集均值与标准差分别为 μ_j 与 s_j ，则标准化后的输入为

$$\tilde{x}_{ij} = \frac{x_{ij} - \mu_j}{s_j}.$$

测试集使用训练集统计量进行相同变换，以避免信息泄漏。在此基础上，本

文比较以下四类核函数。线性核定义为

$$K_{\text{lin}}(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{z},$$

其本质是在原空间中寻找最大间隔超平面，适用于近似线性可分问题。多项式核定义为

$$K_{\text{poly}}(\mathbf{x}, \mathbf{z}) = (\gamma \mathbf{x}^T \mathbf{z} + r)^d,$$

其中 d 为多项式次数， γ 为缩放系数， r 为常数项；本文实验中取 $d = 3$ 。径向基核（RBF 核）定义为

$$K_{\text{rbf}}(\mathbf{x}, \mathbf{z}) = \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|_2^2),$$

其能够基于局部邻域相似性构造高度灵活且平滑的非线性边界。Sigmoid 核定义为

$$K_{\text{sig}}(\mathbf{x}, \mathbf{z}) = \tanh(\gamma \mathbf{x}^T \mathbf{z} + r).$$

本文统一设置 $C = 1.0$ ，并在多项式核、RBF 核与 Sigmoid 核中采用自动缩放的 γ 设置，以保证不同核函数间比较的公平性。通过这四种核函数的对照，可以系统分析不同非线性映射机制对该三维月牙数据分类性能的影响。

总体而言，线性核对应全局线性分隔假设，多项式核对应有限阶全局非线性映射，RBF 核则对应基于局部距离的无限维隐式特征空间，而 Sigmoid 核提供了一种类似神经元激活的非线性相似性度量^[7]。

2.5 实验设置与评价指标

2.5.1 实验设置

为保证实验对比的可复现性与公平性，本文在相同训练集和测试集上分别训练决策树、AdaBoost+Decision Tree 以及四种核函数的 SVM 模型。对于单棵决策树，本文重点比较不同最大深度下的性能变化；对于 AdaBoost，本文固定集成轮数为 100，仅改变基学习器的树深；对于 SVM，本文保持惩罚参数 C 不变，仅比较核函数类型差异。

2.5.2 评价指标

本文采用 Accuracy、F1-score 以及混淆矩阵作为主要评价指标^[8]。设二分类任务中的真正例、真负例、假正例、假负例分别为 TP 、 TN 、 FP 、 FN ，则分类

准确率定义为

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

精确率与召回率分别定义为

$$Precision = \frac{TP}{TP + FP}, Recall = \frac{TP}{TP + FN}$$

在此基础上，F1-score 定义为精确率与召回率的调和平均：

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

此外，混淆矩阵记为

$$C = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$$

可用于分析模型的具体错误类型。由于本文测试集为平衡数据集，两类样本数量完全相同，因此 Accuracy 与 F1-score 在多数情况下具有较好一致性；但混淆矩阵仍然能够揭示模型在不同类别上的偏置情况。

3 实验结果分析

3.1 Decision Tree 的最大深度影响

表 1 Decision Tree 在不同最大深度下的性能比较

最大深度	Accuracy	Precision (C0/C1)	Recall (C0/C1)	F1-score	Confusion Matrix	错分总数
5	0.9180	0.92 / 0.92	0.92 / 0.92	0.9182	[[229, 21], [20, 230]]	41
7	0.9360	0.93 / 0.95	0.95 / 0.92	0.9352	[[237, 13], [19, 231]]	32
9	0.9480	0.95 / 0.95	0.95 / 0.95	0.9480	[[237, 13], [13, 237]]	26
11	0.9500	0.95 / 0.95	0.95 / 0.95	0.9499	[[238, 12], [13, 237]]	25

从表 1 可以看出，单棵决策树的性能随最大深度增加而稳定提升。depth=5 时 Accuracy 为 0.9180，depth=7 提升到 0.9360，depth=9 进一步达到 0.9480，depth=11 时达到最优的 0.9500。与此同时，错分总数从 41 个逐步下降到 25 个。这说明增加树深确实提升了决策树对非线性边界的表达能力。但另一方面，从 depth=9 到 depth=11，Accuracy 仅提升了 0.002，F1-score 也只从 0.9480 变化

到 0.9499，性能增益已经明显减弱。说明当树深达到一定程度后，单棵树对该数据集的拟合能力已接近上限，继续增加复杂度的边际收益有限。

3.2 AdaBoost + Decision Tree 的基学习器深度影响

表 2 AdaBoost + Decision Tree 在不同基学习器最大深度下的性能比较

基学习器 最大深度	Accuracy	Precision (C0/C1)	Recall (C0/C1)	F1-score	Confusion Matrix	错分总数
1	0.7340	0.76 / 0.71	0.69 / 0.78	0.7457	[[172, 78] [55, 195]]	133
3	0.9580	0.97 / 0.95	0.95 / 0.97	0.9584	[[237, 13], [8, 242]]	21
5	0.9700	0.98 / 0.96	0.96 / 0.98	0.9702	[[241, 9], [6, 244]]	15
7	0.9700	0.98 / 0.96	0.96 / 0.98	0.9703	[[240, 10], [5, 245]]	15
9	0.9640	0.96 / 0.96	0.96 / 0.96	0.9640	[[241, 9], [9, 241]]	18

与单棵决策树相比，AdaBoost 对基学习器深度更加敏感。depth=1 时 Accuracy 只有 0.7340，说明仅由树桩构成的弱分类器难以有效表示双月牙数据的复杂边界；但当深度提升到 3 时，Accuracy 迅速升至 0.9580，说明 Boosting 开始能够充分发挥作用；当深度为 5 或 7 时，模型达到最优区间，Accuracy 均为 0.9700，F1-score 分别为 0.9702 和 0.9703；继续提高到 9 时，性能反而下降到 0.9640。这说明在 Boosting 框架下，基学习器并不是越强越好。过浅的树无法提供足够有效的局部划分，导致集成效果有限；过深的树虽然单个分类器更强，但会削弱 AdaBoost 逐轮关注难样本、逐步修正误差的优势，同时更容易将噪声信息也学进去。因此，中等复杂度的基学习器更适合作为 AdaBoost 的基础模型。在本实验中，depth=7 的 F1-score 略高，因此将其作为 AdaBoost + DT 的最终展示配置。

3.3 SVM 四种核函数对比

表 3 四种 SVM 核函数性能比较

核函数	Accuracy	Precision (C0/C1)	Recall (C0/C1)	F1-score	Confusion Matrix	错分总数
Linear	0.6620	0.66 / 0.66	0.67 / 0.66	0.6600	[[167, 83], [86, 164]]	169
Polynomial	0.7480	0.77 / 0.73	0.70 / 0.80	0.7595	[[175, 75], [51, 199]]	126
RBF	0.9720	0.98 / 0.97	0.97 / 0.98	0.9721	[[242, 8], [6, 244]]	14
Sigmoid	0.5360	0.54 / 0.54	0.54 / 0.54	0.5360	[[134, 116], [116, 134]]	232

表 3 显示，不同核函数之间的差距极为显著。Linear 核 Accuracy 仅为 0.6620，说明原始空间中的类别边界绝不是简单的线性超平面；Polynomial 核提高到 0.7480，表明有限阶非线性映射可以部分缓解问题，但仍无法充分拟合复杂局部结构；RBF 核则直接提升到 0.9720，成为全局最优模型；Sigmoid 核仅为 0.5360，甚至接近失效。




图 2 四种核函数的二维切片决策边界图

结果表明，当前三维双月牙数据最适合由局部平滑、可弯曲的非线性边界进行建模。RBF 核通过距离度量定义样本相似性，能够在局部区域灵活调整分类边界，因此最符合数据的几何特征；Polynomial 核虽然引入了非线性，但其非线性形式仍然偏向全局固定阶数变换，面对噪声和局部流形弯曲时适应性有限；Linear 核则完全不具备这种局部变形能力；Sigmoid 核在本任务中与数据分布的匹配性最差，因此无论 Accuracy、Precision、Recall 还是 F1-score 都最低。

3.4 整体分类性能比较

为保证整体比较的一致性，本文采用统一的最优配置对六种方法进行横向比较，即 Decision Tree (max_depth=11)、AdaBoost + Decision Tree (基学习器 max_depth=7)、SVM_Linear、SVM_Polynomial、SVM_RBF 和 SVM_Sigmoid。

表 4 六种方法整体性能对比

方法	Accuracy	Precision (C0/C1)	Recall (C0/C1)	F1-score	Confusion Matrix
Decision Tree	0.9500	0.95 / 0.95	0.95 / 0.95	0.9499	[[238, 12], [13, 237]]
AdaBoost + DT	0.9700	0.98 / 0.96	0.96 / 0.98	0.9703	[[240, 10], [5, 245]]
SVM_Linear	0.6620	0.66 / 0.66	0.67 / 0.66	0.6600	[[167, 83], [86, 164]]
SVM_Polynomial	0.7480	0.77 / 0.73	0.70 / 0.80	0.7595	[[175, 75], [51, 199]]
SVM_RBF	0.9720	0.98 / 0.97	0.97 / 0.98	0.9721	[[242, 8], [6, 244]]
SVM_Sigmoid	0.5360	0.54 / 0.54	0.54 / 0.54	0.5360	[[134, 116], [116, 134]]

从表 4 可以看出，六种方法的性能差异十分明显。总体上，SVM_RBF 的 Accuracy 和 F1-score 均为最高，分别达到 0.9720 和 0.9721，是本实验中表现最好的模型；AdaBoost + Decision Tree 次之，Accuracy 为 0.9700、F1-score 为 0.9703，与 SVM_RBF 非常接近；单棵 Decision Tree 在调到较优深度后也能取得 0.9500 的 Accuracy，但仍略低于前两者。相比之下，SVM_Linear、SVM_Polynomial 和 SVM_Sigmoid 的表现明显较弱，尤其是 Sigmoid 核仅达到 0.5360，几乎接近无效分类。




图 3 Accuracy 与 F1-score 柱状对比图

从 Accuracy 指标看，当前三维双月牙数据的难点在于对非线性边界形状的正确拟合。具有更强非线性表示能力的模型能够在整体正确率上取得明显优势。

从 F1-score 指标看，模型排序与 Accuracy 一致，说明最优模型并不是只在 Precision 或 Recall 某一项上突出，而是在两者之间取得了更好的平衡，因此 F1-score 也达到了最高水平。




图 4 所有模型混淆矩阵对比图

结合混淆矩阵进一步分析可以发现，SVM_RBF 的混淆矩阵为 $\begin{bmatrix} 242 & 8 \\ 6 & 244 \end{bmatrix}$,

总错分仅 14 个，为所有模型中最少；AdaBoost + DT 为 $\begin{bmatrix} 240 & 10 \\ 5 & 245 \end{bmatrix}$ ，总错分 15 个，几乎与 RBF 核持平；Decision Tree 为 $\begin{bmatrix} 238 & 12 \\ 13 & 237 \end{bmatrix}$ ，总错分 25 个，说明其已具备较好的分类能力，但边界刻画仍不如前两者精细。与之形成鲜明对比的是，SVM_Linear 总错分达到 169 个，SVM_Sigmoid 更达到 232 个，表明这两种模型没有有效捕获数据中的真实非线性结构。




图 5 所有方法多模型二维切片决策边界图

从切片图的边界形态可以看出，Decision Tree 的边界呈明显的块状与分段状，这是树模型轴对齐划分的典型特征；AdaBoost + DT 的边界相较单棵树更加细致和平滑，说明集成学习通过多轮加权修正改善了局部判别能力；SVM_Linear 只能给出一条近似直线型分割边界，难以贴合双月牙数据的弯曲结构；SVM_Polynomial 虽然比线性核更灵活，但其边界仍然偏向全局有限阶变换，无法充分适应局部复杂弯曲；SVM_RBF 的边界最平滑且最贴合样本分布；SVM_Sigmoid 的边界则最不稳定，与数据分布的匹配性最差。

因此，从整体性能、四项评价指标、混淆矩阵和决策边界可视化四个角度可以一致得出结论：SVM_RBF 是本实验中综合表现最好的方法，AdaBoost + Decision Tree 是与其最接近的模型，而单棵 Decision Tree 则构成一个性能较强、解释性较好的基线模型。




图 6 SVM_RBF 真实标签与预测错点图

从图 6 可以看到，SVM_RBF 错误样本数量很少，并且主要集中在类别边界附近和局部交叠区域。这说明 RBF 核已经较好地学习到了两类数据的主体结构，其残余错误更多来自噪声扰动和边界模糊区域。

结论

本文针对三维带噪双月牙二分类任务，系统比较了决策树、AdaBoost + Decision Tree 和四种核函数支持向量机的分类性能。实验结果表明，单棵决策树能够通过增加最大深度不断提升性能，但整体仍存在表达能力上限；AdaBoost 通过集成学习显著改善了树模型的分类效果，在基学习器深度为 5 或 7 时达到较优结果；在 SVM 的四种核函数中，RBF 核表现最优，Accuracy 为 0.9720，F1-score 为 0.9721，是本实验中综合性能最好的方法。

综合数值结果与可视化分析可以看出，模型性能的差异本质上来源于其对数据非线性边界的刻画能力。对于本文所研究的三维双月牙数据，能够学习局部平滑非线性边界的模型更适合，其中 SVM_RBF 最优，AdaBoost + Decision Tree 次之，单棵 Decision Tree 则可作为一个较强且具有解释性的基线模型。

参考文献

- [1] “Pattern Recognition and Machine Learning | Springer Nature Link.” Accessed: Mar. 27, 2026. [Online]. Available: <https://link.springer.com/in/book/9780387310732>
- [2] W. Loh, “Classification and regression trees,” *WIREs Data Min. Knowl. Discov.*, vol. 1, no. 1, pp. 14–23, Jan. 2011, doi: 10.1002/widm.8.
- [3] S. R. Safavian and D. Landgrebe, “A survey of decision tree classifier methodology,” *IEEE Trans. Syst. Man Cybern.*, vol. 21, no. 3, pp. 660–674, May 1991, doi: 10.1109/21.97458.
- [4] Y. Freund and R. E. Schapire, “A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting,” *J. Comput. Syst. Sci.*, vol. 55, no. 1, pp. 119–139, Aug. 1997, doi: 10.1006/jcss.1997.1504.
- [5] P. Bartlett, Y. Freund, W. S. Lee, and R. E. Schapire, “Boosting the margin: a new explanation for the effectiveness of voting methods,” *Ann. Stat.*, vol. 26, no. 5, pp. 1651–1686, Oct. 1998, doi: 10.1214/aos/1024691352.
- [6] C. Cortes and V. Vapnik, “Support-vector networks,” *Mach. Learn.*, vol. 20, no. 3, pp. 273–297, Sep. 1995, doi: 10.1007/BF00994018.
- [7] D. Valkenborg, A.-J. Rousseau, M. Geubbelmans, and T. Burzykowski, “Support vector machines,” *Am. J. Orthod. Dentofacial Orthop.*, vol. 164, no. 5, pp. 754–757, Nov. 2023, doi: 10.1016/j.ajodo.2023.08.003.
- [8] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*. in Springer Series in Statistics. New York, NY: Springer New York, 2009. doi: 10.1007/978-0-387-84858-7.