

PRML 作业 3 报告

基于残差 LSTM 的多变量 PM2.5 短期预测研究

黄欣儒 23376061

15928304723@163.com

摘要

本文针对多变量 PM2.5 下一小时短期预测问题，基于所给空气污染与气象数据，比较了 Persistence Baseline、LSTM、LSTM+Temporal Attention 和 Residual LSTM 四种方法。实验采用过去 12 小时的污染值及气象变量作为输入，以下一小时 PM2.5 浓度作为预测目标。实验发现，仅使用上一小时的污染值作为预测值的 Persistence Baseline 已取得较高性能，说明该数据集存在显著短期自相关特征。在此基础上，标准的 LSTM 并未明显超过基准方法，引入 LSTM+Temporal Attention 性能反而下降，表明单纯增加模型复杂度并不能保证预测精度提升。

基于上述分析，本文进一步采用 Residual LSTM，将预测目标由污染值绝对值转化为相邻小时污染变化量。实验结果表明，Residual LSTM 在 2014 测试集和附加测试集上均取得最优 MAE、RMSE 和 R^2 ，其中在 2014 测试集上达到 $MAE = 12.28$ 、 $RMSE = 23.88$ 、 $R^2 = 0.935$ 。结果说明，Residual LSTM 能够在强短期自相关基准上学习有效修正项，但其提升幅度有限，也进一步验证了下一小时 PM2.5 预测主要受最近时刻污染水平支配。

关键词：PM2.5 预测；多变量时间序列；LSTM；Temporal Attention；Residual Learning

Abstract

This study investigates the next-hour short-term forecasting problem of multivariate PM2.5. Based on the given air pollution and meteorological data, four methods are compared: Persistence Baseline, LSTM, LSTM with Temporal Attention, and Residual LSTM. The experiments use the pollution values and meteorological variables from the previous 12 hours as inputs, with the PM2.5 concentration in the next hour as the prediction target. The results show that the Persistence Baseline, which directly uses the pollution value from the previous hour as the prediction, already achieves strong performance. This indicates that the dataset exhibits significant short-term autocorrelation. On this basis, the standard LSTM does not clearly outperform the baseline method, and introducing LSTM with Temporal Attention even leads to degraded performance, suggesting that simply increasing model complexity does not necessarily improve forecasting accuracy.

Based on the above analysis, this study further adopts Residual LSTM, which transforms the prediction target from the absolute pollution value into the pollution change between adjacent hours. The experimental results show that Residual LSTM achieves the best MAE, RMSE, and R^2 on both the 2014 test set and the additional test set. On the 2014 test set, it achieves $MAE = 12.28$, $RMSE = 23.88$, and $R^2 = 0.935$. These results indicate that Residual LSTM can learn effective correction terms on top of a strong short-term autocorrelation baseline. However, the improvement remains limited, which further confirms that next-hour PM2.5 forecasting is mainly dominated by the pollution level at the most recent time step.

Keywords: PM2.5 forecasting; multivariate time series; LSTM; Temporal Attention; Residual Learning.

1 引言

PM2.5 是衡量空气污染程度的重要指标之一，其浓度变化与居民健康、空气质量预警和城市环境治理紧密相关^[1]。由于 PM2.5 的变化不仅受历史污染水平影响，还与温度、气压、风速和降雨等气象因素相关，因此可结合多变量时间序列对短期 PM2.5 浓度进行准确预测。

本文基于历史污染数据和气象观测数据，预测下一小时的 PM2.5 浓度。具体而言，模型使用过去 12 小时的多变量观测序列作为输入，输出下一小时的气候污染值。模型核心难点在于如何有效利用历史时间序列中的动态变化信息，同时避免模型复杂度过高导致泛化能力下降。

从数据特征来看，PM2.5 在小时级的尺度上通常具有较强的短期连续性，即下一小时的污染水平往往与上一小时高度相关。对数据进行分析发现，使用上一小时的污染水平作为预测值，可能已经能够取得较强的基准效果，因此，推测仅仅构建复杂的神经网络模型并不一定能够显著提升预测精度。

基于这一问题特点，本文逐步递进进行模型的构建与验证：

- 1) 建立 Persistence Baseline^[2]，检验上一小时污染值对下一小时预测的基准能力；
- 2) 构建标准 LSTM 模型^[3]，验证其对多变量时间序列依赖关系的建模能力，由实验数据分析发现标准 LSTM 未能明显超过 Persistence Baseline；

- 3) 本文进一步尝试引入 Temporal Attention^[4]机制，以增强模型对不同历史时间步重要性的刻画。然而，Attention-LSTM 的结果并不理想；

- 4) 基于对数据短期自相关特征的分析，本文最终采用 Residual LSTM^{[5],[6]}，将预测目标由污染绝对值转化为相邻小时污染变化量，从而使模型在 Persistence Baseline 的基础上学习修正项。实验结果表明，Residual LSTM 在主要评价指标上取得了最优表现，但其提升幅度有限，这也进一步验证了理论推测，即下一小时 PM2.5 预测主要受短期自相关结构支配。

2 数据集与实验设置

2.1 数据集说明

本文使用小时级多变量空气污染数据集进行 PM2.5 短期预测实验。数据集覆盖 2010 年至 2014 年，共包含约 43800 条小时级观测记录，每条记录对应一个时间点的空气污染与气象变量。由于历史污染水平本身对下一小时 PM2.5 具有重要影响，本文将历史 pollution 也作为输入特征之一，与气象变量共同用于预测下一小时污染浓度。

2.2 时间序列样本构造

原始数据按照小时顺序排列，本文采用滑动窗口方法构造输入样本和预测目标。设时间窗口长度为 12 小时，则对于任意预测时刻 t ，模型输入为过去 12 小时的多变量观测序列：

$$X_t = [x_{t-12}, x_{t-11}, \dots, x_{t-1}]$$

预测目标为当前时刻的 PM2.5 浓度：

$$y_t = pollution_t$$

其中， x_i 表示第*i*个小时的多变量特征向量，包括历史 pollution 和气象变量。本文为下一小时的短期预测，最近若干小时的污染变化通常比更长历史信息更直接相关，12 小时窗口能够覆盖半天内的短期污染变化趋势，同时避免过长窗口引入过多无关噪声，因此，本文采用 12 小时时间窗口。

2.3 数据集划分与预处理

本文按照年份顺序划分数据集：

表 1 数据集划分

数据集	年份	用途
Training set	2010–2012	模型训练
Validation set	2013	参数调整与早停
Test set	2014	最终性能评估

数据预处理阶段：对缺失值进行处理：数值型变量采用线性插值与前后填充，风向等类别变量则采用前后填充；对风向特征进行独热编码，避免标签编码引入的错误序关系。数值特征采用归一化，归一化器仅在训练集上拟合，并以同一参数转换验证、测试集。

2.4 评价指标

为了全面评估模型预测性能，本文采用 MAE、RMSE 和 R^2 作为评价指标。

MAE 衡量预测值与真实值之间的平均绝对误差，表示模型平均预测误差大小：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

RMSE 对较大误差更敏感，反映模型在污染峰值或突变情况下的预测偏差：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

R^2 衡量模型对目标变量方差的解释能力， R^2 越接近 1，说明模型对污染浓度变化的解释能力越强：

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

3 方法

3.1 基准方法：Persistence Baseline

本文采用 Persistence Baseline^[2]作为基准方法作为参考。该方法基本假设为：短时间间隔内目标变量变化有限，因此下一时刻的预测值可以直接使用上一时刻的观测值表示：

$$\hat{y}_t = y_{t-1}$$

其中， y_{t-1} 表示上一小时的真实 pollution 值， $\hat{y}_t$ 表示对当前小时 pollution 的预测值。

虽然 Persistence Baseline 不使用任何复杂模型结构，也不利用其他气象变量，但由于小时级 PM2.5 序列通常具有较强短期自相关性，即下一小时污染浓度往往与上一小时高度接近，因此该模型可作为基准模型为后续模型设计提供参考。如果复杂模型不能明显超过该基准，则说明模型并未有效利用额外特征或复杂结构带来实质性提升。

表 2 Persistence Baseline 测试集结果

Test Dataset	MAE	RMSE	R^2
2014 测试集	12.43	24.51	0.931
附加测试集	14.51	26.88	0.926

实验结果表明，仅使用上一小时 pollution 作为预测值，模型已经取得较高的 R^2 ，同时进一步从 lag-1 相关性分析可以看出，当前时刻的 pollution_t 与上一小时的 pollution_{t-1} 呈现显著正相关关系，即该数据集中的下一小时 PM2.5 预测高度依赖最近时刻的污染水平，短期自相关为主导因素。




图 1 Persistence Baseline 测试集结果




图 2 数据集 lag-1 散点图

3.2 初始模型：LSTM

LSTM^[3]是循环神经网络的一种改进结构，能够通过门控机制缓解传统 RNN 在长序列建模中容易出现的梯度消失问题。LSTM 主要由输入门、遗忘门和输出门组成，可以控制历史信息的保留、更新和输出，适合用于时间序列预测任务。

本文首先构建 LSTM 作为初始深度学习模型。模型输入为过去 12 小时的多变量观

测序列，包括历史 pollution 和气象特征；输出为下一小时 pollution 的绝对值。其预测形式为：

$$\hat{y}_t = f_{\theta}(X_t)$$

其中， X_t 表示过去 12 小时的输入序列， f_{θ} 表示 LSTM 模型学习到的非线性映射关系。

模型结构如下：




图 3 LSTM 结构图

表 3 LSTM 测试集结果

Test Dataset	MAE	RMSE	R ²
2014 测试集	15.93	25.89	0.923
附加测试集	15.59	26.94	0.926

实验结果表明，LSTM 并没有明显超过 persistence Baseline。在 2014 测试集上，LSTM 的 MAE 和 RMSE 均高于 Persistence Baseline， R^2 也略低。这说明在该短期预测任务中，直接预测 pollution 绝对值的 LSTM 并未充分利用上一小时污染值这一强预测因子。换言之，虽然 LSTM 具备建模时间依赖的能力，但对于下一小时 PM2.5 的预测而言，简单的短期连续性已经提供了很强的信息基础。故在进一步改进模型时，不能仅依赖更复杂的神经网络结构，而需要结合数据本身的短期自相关特征重新设计预测目标或模型形式。




图 4 LSTM 测试集结果

3.3 改进尝试：LSTM+Temporal Attention

在 LSTM 中，模型主要依赖最后一个 hidden state 进行预测。然而，过去 12 小时中不同时间步对下一小时 PM2.5 的影响可能并不相同。基于这一考虑，本文进一步尝试引入 Temporal Attention^[4]机制，使模型能够自动学习不同历史时间步的重要性。

设 LSTM 对过去 12 个时间步输出的 hidden states 为：

$$H = [h_{t-12}, h_{t-11}, \dots, h_{t-1}]$$

Temporal Attention 首先为每个 hidden state 计算注意力权重：

$$\alpha_i = \frac{\exp(e_i)}{\sum_j \exp(e_j)}$$

其中， e_i 表示第*i*个时间步的注意力得分。随后，模型根据注意力权重对所有 hidden states 进行加权求和，得到上下文向量：

$$c_t = \sum_i \alpha_i h_i$$

为了避免注意力加权过程削弱最近时间步信息，本文采用改进版 Attention-LSTM 结构，即不仅使用 attention 得到的 context vector，同时保留 LSTM 的最后一个 hidden state，并将二者拼接后用于最终预测：

$$z_t = [c_t; h_{t-1}] \quad \hat{y}_t = f_\theta(z_t)$$

该方法旨在增强模型对历史时间步重要性的区分能力，从而提升对污染变化趋势的刻画能力。

表 4 LSTM+Temporal Attention 伪代码

算法 1 LSTM+Temporal Attention

Input: $X_t = [x_{t-12}, x_{t-11}, \dots, x_{t-1}]$

1. $H = \text{LSTM}(X_t, \text{return_sequences}=\text{True})$
2. $H = \text{Dropout}(H)$
3. $\alpha = \text{Softmax}(\text{AttentionScore}(H))$
4. $c_t = \sum_i \alpha_i h_i$
5. $h_{\text{last}} = h_{t-1}$
6. $z_t = \text{Concat}(c_t, h_{\text{last}})$
7. $z_t = \text{Dense}_{\text{ReLU}}(z_t)$
8. $\hat{y}_t = \text{Dense}(z_t)$

Output: predicted PM2.5 value $\hat{y}_t$

表 5 LSTM+Temporal Attention 测试集结果

Test Dataset	MAE	RMSE	R ²
2014 测试集	73.52	87.94	0.117
附加测试集	35.48	49.74	0.754

结果显示, 引入 Temporal Attention 后模型性能明显下降。虽然注意力机制理论上能够帮助模型识别关键历史时间步, 但在本文预测任务中并未带来有效提升。其可能原因是该任务主要依赖最近一小时或最近几小时的污染水平, 而 attention 对多个历史时间步进行加权后, 可能削弱了最近时刻信息的主导作用, 使预测结果趋于平滑, 从而降低了对污染峰值和快速变化的响应能力。




图 5 LSTM+Temporal Attention 测试集结果

因此, 实验表明, 对于该短期预测任务, 模型改进的关键不在于引入更复杂的时间步加权机制, 而在于如何更直接地利用上一小时 pollution 这一强预测信息。

3.4 最终实现：Residual LSTM

根据前述实验，Persistence Baseline 已经取得较高预测精度，而 LSTM 和 Attention-LSTM 均未能稳定超过该基准。这表明下一小时 PM2.5 预测主要受到短期自相关影响， y_t 与 y_{t-1} 之间具有很强联系。

基于这一观察，本文采用 Residual Learning^{[5], [6]} 思路对预测目标进行重新定义。不同于 LSTM 直接预测 pollution 的绝对值，Residual LSTM 预测当前小时与上一小时之间的污染变化量：

$$\Delta y_t = y_t - y_{t-1}$$

模型学习目标变为：

$$\widehat{\Delta y}_t = g_{\theta}(X_t)$$

最终预测值由上一小时 pollution 与模型预测的变化量相加得到：

$$\hat{y}_t = y_{t-1} + \widehat{\Delta y}_t$$

Residual LSTM 可以理解为在 Persistence Baseline 基础上学习一个修正项。如果模型预测的变化量接近 0，则该方法退化为 Persistence Baseline；如果模型能够捕捉污染上升或下降趋势，则可以在强基准基础上进一步提高预测精度。相比直接预测 pollution 绝对值，预测变化量降低了模型学习难度，也更符合短期 PM2.5 序列的连续性特征。

表 6 Residual LSTM 伪代码

算法 2 Residual LSTM

Input: $X_t = [x_{t-12}, x_{t-11}, \dots, x_{t-1}]$

1. $H = \text{LSTM}(X_t, \text{return_sequences}=\text{True})$
2. $H = \text{Dropout}(H)$
3. $\alpha = \text{Softmax}(\text{AttentionScore}(H))$
4. $c_t = \sum_i \alpha_i h_i$
5. $h_{\text{last}} = h_{t-1}$
6. $z_t = \text{Concat}(c_t, h_{\text{last}})$
7. $z_t = \text{Dense}_{ReLU}(z_t)$
8. $\hat{y}_t = \text{Dense}(z_t)$

Output: predicted PM2.5 value $\hat{y}_t$

表 7 Residual LSTM 测试集结果

Test Dataset	MAE	RMSE	R ²
2014 测试集	12.28	23.88	0.935
附加测试集	13.67	25.52	0.933

实验结果表明，Residual LSTM 在 2014 测试集和附加测试集上均取得最优 MAE、RMSE 和 R^2 。这说明将预测目标由污染绝对值转化为污染变化量是有效的，模型能够在 Persistence Baseline 的基础上进一步学习污染变化趋势。




图 6 Residual LSTM 测试集结果

不过，Residual LSTM 相比 Persistence Baseline 的提升幅度并不大。这一现象进一步说明该任务本身具有很强的短期自相关性，即上一小时 pollution 已经包含了大量预测信息，复杂模型能够带来的边际增益有限。

4 结论

本文围绕多变量 PM2.5 下一小时预测任务，按照，基准模型—初始深度学习模型—注意力机制改进—残差学习改进的递进思路进行了实验分析：

1) Persistence Baseline 在 2014 测试集上取得 $MAE = 12.43$ 、 $RMSE = 24.51$ 、 $R^2 = 0.931$ 的结果，说明仅使用上一小时 pollution 已能获得较高预测精度。结合 lag-1 相关性分析可以看出，PM2.5 序列在小时级尺度上具有明显短期自相关特征，下一小时污染水平高度依赖最近时刻的污染值。

2) 本文进一步构建标准 LSTM 模型，以验证其对多变量时间序列关系的建模能力。然而实验结果显示，LSTM 在 2014 测试集上的 MAE 和 RMSE 均高于 Persistence Baseline，未能有效超越简单基准。这说明在该短期预测任务中，直接预测 pollution 绝对值并不能充分利用上一小时污染值这一强预测因子。

3) 随后本文引入的 LSTM+Temporal Attention 也未取得预期改进，其性能明显下降，表明注意力机制在该任务中可能削弱了最近时间步信息的主导作用，使预测结果趋于平滑，从而降低了对污染峰值和快速变化的响应能力。

4) 基于上述实验现象，本文采用 Residual LSTM，将预测目标从 pollution 绝对值转化为相邻小时之间的污染变化量。该方法可以理解为在 Persistence Baseline 基础上学习一个修正项，更符合 PM2.5 短期预测中强连续性的特点。实验结果表明，Residual LSTM 在 2014 测试集上取得 $MAE = 12.28$ 、 $RMSE = 23.88$ 、 $R^2 = 0.935$ ，在附加测试集上取得 $MAE = 13.67$ 、 $RMSE = 25.52$ 、 $R^2 = 0.933$ ，均为各方法中的最优结果。这说明残差学习能够有效利用污染序列的短期变化趋势，并在强基准基础上进一步提升预测性能。

表 8 不同模型测试集对比

Model	Test Dataset	MAE	RMSE	R ²
Persistence Baseline	2014 测试集	12.43	24.51	0.931
	附加测试集	14.51	26.88	0.926
LSTM	2014 测试集	15.93	25.89	0.923
	附加测试集	15.59	26.94	0.926
LSTM+Temporal Attention	2014 测试集	73.52	87.94	0.117
	附加测试集	35.48	49.74	0.754
Residual LSTM	2014 测试集	12.28	23.88	0.935
	附加测试集	13.67	25.52	0.933

不过，Residual LSTM 相比 Persistence Baseline 的提升幅度仍然有限，反映出该任务本身的预测上限受到短期自相关结构的限制，即当上一小时 pollution 已经包含大量预测信息时，复杂模型能够带来的边际增益相对有限。因此，对于下一小时 PM2.5 短期预测任务，模型设计应优先考虑数据本身的时间相关特征；相比单纯增加网络复杂度，基于短期自相关结构重新定义预测目标，即使用 Residual LSTM 预测污染变化量，是更有效且更合理的建模方式。




图 7 不同模型测试集对比

未来可以从以下几个方向进一步进行改进：一是扩充数据集，引入更丰富的外部变量，例如交通流量、工业排放、节假日和空间位置因素，以弥补现有特征对污染突变解释能力的不足；二是扩展预测任务到多步预测，检验模型在更长预测范围内的稳定性；三是可以尝试结合 TCN、CNN-LSTM 等模型，与 Residual LSTM 进行更全面的对比，以进一步分析不同模型在短期与中长期污染预测中的适用性。

参考文献

- [1] H. D. Tran, H.-Y. Huang, J.-Y. Yu, and S.-H. Wang, “Forecasting hourly PM2.5 concentration with an optimized LSTM model,” *Atmos. Environ.*, vol. 315, p. 120161, Dec. 2023, doi: 10.1016/j.atmosenv.2023.120161.
- [2] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, “The M4 Competition: 100,000 time series and 61 forecasting methods,” *Int. J. Forecast.*, vol. 36, no. 1, pp. 54–74, Jan. 2020, doi: 10.1016/j.ijforecast.2019.04.014.
- [3] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, Nov. 1997, doi: 10.1162/neco.1997.9.8.1735.
- [4] A. Vaswani *et al.*, “Attention is All you Need,” in *Advances in Neural Information Processing Systems*, Curran Associates, Inc., 2017. Accessed: Apr. 30, 2026. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html
- [5] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA: IEEE, Jun. 2016, pp. 770–778. doi: 10.1109/CVPR.2016.90.
- [6] Z. Liu, D. Ji, and L. Wang, “PM2.5 concentration prediction based on EEMD-ALSTM,” *Sci. Rep.*, vol. 14, no. 1, p. 12636, Jun. 2024, doi: 10.1038/s41598-024-63620-9.