

PRML 作业 4 报告

Transformer 复现与位置编码消融实验

黄欣儒 23376061

15928304723@163.com

摘要

本文基于 IWSLT 英德翻译数据集对 Vaswani 等人 Transformer 模型展开复现与消融实验。《Attention Is All You Need》提出了一种完全基于注意力机制的序列到序列模型，用自注意力机制替代传统循环神经网络和卷积神经网络，在机器翻译任务上展现出较强的并行计算能力和序列建模能力。

本文复现了 Transformer 的核心结构，并基于 IWSLT 2017 英德翻译数据集训练了小型 Transformer 模型。围绕位置编码模块对模型进行消融实验，对比了原文正弦位置编码、可学习绝对位置编码和不使用位置编码三种设置。

实验结果表明，使用原文正弦位置编码的模型取得最佳结果，最终 BLEU 为 17.13；使用可学习绝对位置编码的模型 BLEU 为 15.89，性能接近但略低于原文方法；完全去除位置编码后，BLEU 显著下降到 6.26，并且翻译结果中出现明显的重复、语序混乱和语义偏移。因此，通过实验可知，位置编码是 Transformer 处理序列顺序信息的重要模块。自注意力能够建模词元之间的依赖关系，但如果没有位置编码，模型很难区分词元的顺序和句法结构。

关键词：Transformer；自注意力机制；位置编码；机器翻译；消融实验；IWSLT 2017

Abstract

This paper reproduces the Transformer model proposed by Vaswani et al. and conducts ablation experiments on positional encoding using the IWSLT 2017 English-German translation dataset. *Attention Is All You Need* introduces a sequence-to-sequence model based entirely on attention mechanisms, replacing traditional recurrent neural networks and convolutional neural networks with self-attention. The model shows strong parallelization ability and sequence modeling performance in machine translation tasks.

In this work, the main components of Transformer are reproduced. A small Transformer model is trained on the IWSLT 2017 English-German translation dataset. Based on this model, ablation experiments are conducted on positional encoding by comparing three settings: sinusoidal positional encoding, learned absolute positional encoding, and no positional encoding.

The experimental results show that the model using sinusoidal positional encoding achieves the best performance, with a final BLEU score of 17.13. The model using learned absolute positional encoding obtains a BLEU score of 15.89, which is close to but slightly lower than the original method. When positional encoding is removed completely, the BLEU score drops significantly to 6.26, and the generated translations show obvious repetition, word-order confusion, and semantic drift. These results indicate that positional encoding is an essential component for Transformer to process sequential order information. Although self-attention can model dependencies between tokens, without positional encoding the model has difficulty distinguishing token order and syntactic structure.

Keywords: Transformer; self-attention mechanism; positional encoding; machine translation; ablation experiment; IWSLT 2017

1 引言

序列到序列建模是自然语言处理中的核心问题之一，经典任务包括机器翻译、文本摘要、问答生成等。早期神经机器翻译模型主要依赖循环神经网络，尤其是 LSTM 和 GRU 等结构。循环模型天然按照时间步处理序列，因此能够保留输入顺序信息，但其也存在明显缺陷，即序列必须逐步计算，难以充分并行化，长距离依赖也容易受到路径长度和梯度传播问题的影响。

《Attention Is All You Need》^[1]提出的 Transformer 改变了这一范式。该模型完全去除了循环和卷积结构，主要依靠自注意力在序列内部建立词元与词元之间的依赖关系。原论文指出，Transformer 使用编码器—解码器架构，编码器和解码器都由多层注意力子层和前馈网络子层堆叠而成，并通过残差连接和层归一化保证训练稳定性。与 RNN 相比，自注意力可以在常数路径长度内连接序列中任意两个位置，从而更有利于建模长距离依赖。

然而，Transformer 去除了 RNN 和 CNN 后，也带来了一个重要问题，即模型本身不再天然知道词元的顺序。RNN 通过时间步顺序处理序列，CNN 通过卷积窗口获得局部位置结构，而自注意力只根据词元表示之间的相似性计算注意力权重。如果不额外注入位置信息，模型难以区分“I love you”和“you love I”这类词元相同但顺序不同的句子。因此，原文在输入词嵌入中加入位置编码，其中基准 Transformer 使用固定的正弦位置编码。

本文主要工作为：

- 1) 复现 Transformer 的主要结构，并在真实机器翻译数据集上训练模型。
- 2) 围绕位置编码模块进行消融实验，分析位置编码在 Transformer 中的核心作用。
- 3) 基于 IWSLT 2017 English-German 翻译数据集进行实验验证，并比较三种位置编码设置。


2 方法

2.1 复现路线

本文依据《Attention Is All You Need》中的结构，从基础模块逐步搭建了一个可训练的 Transformer。为调试方便，本文逐步递进建模，即首先在反转序列这类合成序列到序列任务上验证模型结构；在确认模型完成基本序列建模后，再将模型迁移到真实机器翻译任务 IWSLT 2017 English-German 上进行训练和消融实验。

这一过程可以分为四步：

- 1) 实现核心算子，包括 Scaled Dot-Product Attention、Multi-Head Attention、Position-wise Feed-Forward Network、Residual Connection 和 Layer Normalization。
- 2) 构建完整的编码器—解码器结构，并在合成序列到序列任务上进行合理性检验。
- 3) 引入真实机器翻译数据集、shared BPE tokenizer、label smoothing、Noam learning rate schedule 和 beam search，此时训练流程已接近原论文。
- 4) 在稳定的 IWSLT 基准模型上仅改变位置编码方式，比较正弦位置编码、可学习绝对位置编码和不使用位置编码三种设置。



2.2 Transformer 总体结构

本文复现模型采用编码器—解码器架构。给定源语言句子，编码器将输入词元序列映射为一组上下文表示；解码器在生成目标语言句子时，一方面通过带掩码的多头自注意力读取已经生成的目标端词元，另一方面通过编码器—解码器注意力从编码器输出中提取源语言信息。与原论文一致，编码器和解码器都由若干个相同结构的层堆叠而成。编码器层包含两个子层：多头自注意力子层和逐位置前馈网络子层。解码器层在此基础上额外加入编码器—解码器注意力子层，用于

连接源语言表示和目标语言生成过程。

2.3 输入表示与位置编码

Transformer 首先将词元编号映射为连续向量。设词表大小为 V ，隐藏维度为 d_{model} ，则每个词元被映射为一个 d_{model} 维向量。还原原论文做法，词嵌入向量会先乘以 $\sqrt{d_{model}}$ ，再与位置编码相加：

$$X = \text{Embedding}(x) \cdot \sqrt{d_{model}} + PE$$

由于 Transformer 不包含循环结构和卷积结构，自注意力本身不显式感知词元的顺序。因此，位置编码承担了向模型注入序列顺序信息的作用。

本文围绕这一模块设计了三种设置：

1) 原论文使用的正弦位置编码：

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

其中 pos 表示词元在序列中的位置， i 表示维度索引。偶数维使用正弦函数，奇数维使用余弦函数。该方法不引入额外可训练参数，而是通过不同频率的周期函数为不同位置生成固定编码。

从图 1 可以看出，不同维度对应不同变化频率：低维度变化较快，高维度变化较慢。这说明正弦位置编码能够同时提供局部位置变化和较长范围的位置趋势信息。由图 2 可知，位置越接近，相似度通常越高；位置距离增大后，相似度逐渐发生变化。这说明正弦位置编码不仅能够表示绝对位置，也能够为模型提供一定的相对位置线索，有助于自注意力机制判断词元之间的顺序关系。




图 1 正弦位置编码热力图




图 2 正弦位置编码位置相似度图

2) 可学习绝对位置编码。该方法为每一个绝对位置学习一个向量：

$$PE_{pos} = \text{Embedding}_{pos}(pos)$$

它的优点是实现简单，模型可以根据训练数据自动学习位置表示；缺点则是对训练阶段没有见过的更长位置可能缺少自然外推能力。

3) 不使用位置编码，即无位置编码。该设置用于消融实验，目的是观察在缺少显式顺序信息时，Transformer 的翻译能力会发生怎样的变化。

2.4 缩放点积注意力

注意力机制是让模型根据当前词元的查询向量，从一组键值对中选择相关信息。本文复现的核心注意力形式为缩放点积注意力：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中， Q 表示 Query 矩阵， K 表示 Key 矩阵， V 表示 Value 矩阵。 QK^T 用于计算查询向量和键向量之间的相似度；除以 $\sqrt{d_k}$ 避免当维度较大时点积数值过大，导致归一化指数函数进入梯度较小的饱和区域。经过归一化指数函数后得到的注意力权重会对 V 做加权求和，从而得到融合上下文信息的新表示。

在编码器自注意力中， Q, K, V 都来自编码器上一层输出；在解码器带掩码自注意力中， Q, K, V 都来自解码器已生成部分；在编码器—解码器注意力中， Q 来自解码器，而 K, V 来自编码器输出。

2.5 多头注意力

单个注意力头只能在一个表示子空间中计算词元间关系。多头注意力将输入分别投影到多个子空间中，并行计算多个注意力头，再将结果拼接并线性变换：

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O$$

其中：

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$$

本文模型使用 $h = 4$ 个注意力头， $d_{model} = 256$ ，因此每个注意力头的维度为 64。多头注意力允许模型从不同表示子空间、不同依赖关系角度同时观察序列。例如某些注意力头可能更关注局部短语关系，另一些注意力头可能更关注长距离依赖或源目标对齐关系。

2.6 逐位置前馈网络

每个编码器层和解码器层中都包含逐位置前馈网络。它对每个位置单独应用相同的两层前馈网络：

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

该模块不直接建模词元间交互，而是对每个位置的上下文表示做非线性变换。换言之，注意力模块主要负责不同位置之间的信息交互，逐位置前馈网络负责增强每个位置表示本身的表达能力。

2.7 残差连接、层归一化与掩码机制

为了稳定深层网络训练，每个子层外部都使用残差连接和层归一化。本文采用原论文的 Post-LN 形式：

$$\text{LayerNorm}(x + \text{Sublayer}(x))$$

残差连接让信息和梯度更容易跨层传播，层归一化则有助于稳定每一层的激活分布。

在解码器中，本文还复现了因果掩码机制。机器翻译生成过程是自回归的，预测第 t 个目标词元时，只能依赖 $1, \dots, t-1$ 的历史词元，而不能看到未来词元。因此，解码器自注意力中会将未来位置的注意力分数屏蔽掉，保证生成过程符合自回归约束。

2.8 解码方法

训练时，解码器输入为右移后的目标序列，即以起始符号开始，后面接真实目标词元；模型学习预测下一个词元。推理时，模型从起始符号开始逐步生成目标句子，每一步根据当前已生成内容预测下一个词元，直到生成结束符号或达到最大长度。本文使用束搜索进行自回归生成。为了与原论文机器翻译实验尽量对齐，beam size 设置为 4，length penalty 系数设置为 $\alpha = 0.6$ 。最终使用 BLEU 评价生成译文与参考译文之间的匹配程度。

3 实验设置

本文在 IWSLT 2017 English-German 翻译数据集上进行实验，任务为将英文句子翻译为德文句子。由于原论文使用的 WMT14 数据集规模较大，考虑到笔记本配置，完整复现实验成本较高，本文选择 IWSLT 作为同任务形式的小规模数据集。

本文设置三组对比实验：第一组使用原论文的正弦位置编码，第二组使用可学习绝对位置编码，第三组不使用位置编码。三组实验保证位置编码方式为单一变量。

表 1 实验参数设置

设置项	取值	设置项	取值
数据集	IWSLT 2017 英德翻译	丢弃率	0.1
训练样本数	50,000	标签平滑	0.1
验证样本数	888	优化器	Adam
词表构建	英德共享 BPE 词表	$\beta_1, \beta_2, \epsilon$	0.9, 0.98, 10^{-9}
词表大小	16,000	预热步数	4000
最大源序列长度	128	训练轮数	30
最大目标序列长度	128	批大小	64
编码器层数	4	梯度裁剪	1.0
解码器层数	4	解码方式	束搜索
隐藏维度	256	束宽	4
注意力头数	4	长度惩罚系数	0.6
前馈网络隐层维度	1024	评价指标	验证损失、词级准确率、BLEU

训练时，解码器输入为右移后的目标序列，即起始符加目标句子；预测目标为目标句子加结束符。训练结束后，选取验证损失最低的模型进行翻译生成，并计算 BLEU 分数。

本文实验在 Windows 环境下完成，使用 Python 3.11、PyTorch 2.5.1 和 CUDA 12.1 版本的 GPU 环境。

4 实验结果与分析

本章比较三种位置编码方式在英德翻译任务上的表现。三组实验保证位置编码方式为单一变量。

表 2 三组实验结果

位置编码方式	验证损失	词级准确率	BLEU
正弦位置编码	3.7134	0.538	17.13
可学习绝对位置编码	3.8765	0.512	15.89
无位置编码	4.7356	0.350	6.26

从整体结果看，正弦位置编码取得最佳表现，验证损失最低，词级准确率和 BLEU 最高。可学习绝对位置编码的结果略低于正弦位置编码，但仍保持了较好的翻译能力。无位置编码的模型性能明显下降，BLEU 只有 6.26，说明位置编码对 Transformer 的序列建模和翻译质量具有关键作用。

4.1 实验结果

由验证损失曲线可知，三组模型在训练前期验证损失均下降，说明模型都能够学习一定的词汇映射关系。但正弦位置编码下降最稳定，并最终达到最低验证损失。可学习绝对位置编码曲线与正弦位置编码接近，但后期验证损失略高。无位置编码虽然训练损失继续下降，但验证损失在中后期明显停滞，说明模型泛化能力较弱。




图 3 验证损失曲线对比图

从词级准确率看，正弦位置编码最终达到 0.538，可学习绝对位置编码达到

0.512，二者差距不大；无位置编码仅约为 0.35，明显低于前两组。这说明如果没有显式位置信息，模型虽然仍能预测部分高频词，但难以稳定预测符合句子结构的目标词序。

从 BLEU 对比看，正弦位置编码的 BLEU 为 17.13，可学习绝对位置编码为 15.89，仅低 1.24；而无位置编码下降到 6.26，比正弦位置编码低 10.87。这一差距说明，位置编码不仅影响单词预测准确率，也会显著影响整句翻译质量。

翻译示例也能体现这种差异。对于句子，

“It expands in winter and contracts in summer.”

正弦位置编码生成了，

“Es erweitert im Winter und im Sommer.”

虽然漏译了“contracts”，但保留了“winter”和“summer”的基本时间结构。可学习绝对位置编码生成，

“Sie erweitert im Winter und im Sommer.”

效果与正弦位置编码接近。无位置编码生成，

“Es wird im Sommer im Winter und im Winter.”

出现了时间顺序混乱和重复，将“summer”和“winter”的顺序混乱，并重复生成“im Winter”，说明模型缺少显式顺序信息后，即使在较短句子中也难以稳定表达词语先后关系。而对于较长句子，

“Last year I showed these two slides so that demonstrate that the arctic ice cap, which for most of the last three million years has been the size of the lower 48 states, has shrunk by 40 percent.”

正弦位置编码和可学习绝对位置编码都能保留“Last year”“arctic ice cap”“three million years”“40 percent”等主要信息，说明二者都能帮助模型维持一定的句子结构。相比之下，无位置编码模型出现了明显重复，如“die Größe der Größe”，并且原句中的“arctic ice cap”和“has shrunk by 40 percent”等关键信息发生偏移，说明缺少位置信息后模型难以处理长距离依赖和复杂修饰结构。

4.2 分析与讨论

实验结果说明，位置编码的核心作用是向 Transformer 注入词序信息。自注意力本身可以计算任意两个词元之间的相关性，但如果输入中没有位置信息，模型看到的更像是一组无序词元，因此难以区分相同词汇在不同顺序下的不同含义。原论文也指出，由于 Transformer 没有循环和卷积结构，必须额外加入相对或绝对位置信息，使模型能够利用序列顺序。

正弦位置编码在本实验中表现最好，分析如下：第一，它通过固定的正弦和余弦函数提供连续、平滑的位置表示，不需要额外学习参数，在小规模训练数据下更稳定。第二，它包含不同频率的位置变化，有助于模型同时感知短距离和长距离的位置信息。

可学习绝对位置编码的表现略低，但仍然有效，说明模型确实可以通过训练学习位置向量。不过，这种方式依赖训练数据来学习每个位置的表示，在数据规模有限时可能不如固定正弦编码稳定。

无位置编码的结果最差，说明 Transformer 并不能仅依靠自注意力完成高质量序列建模。它可以学习部分词汇对应关系，但缺少顺序线索后，翻译中容易出现重复、漏译和语序混乱。因此，位置编码不是简单的附加模块，而是 Transformer 在无循环、无卷积结构下处理自然语言序列的必要组成部分。

5 结论

本文对《Attention Is All You Need》中的 Transformer 模型进行了结构复现和位置编码消融实验。通过在 IWSLT 2017 数据集上的实验可知，Transformer 的编码器—解码器结构能够在没有循环神经网络和卷积神经网络的情况下完成机器翻译任务。多头自注意力机制负责建模序列中不同词元之间的依赖关系，逐位置前馈网络进一步增强每个位置表示的非线性表达能力，残差连接和层归一化则保证了深层网络训练的稳定性。

实验结果表明，位置编码对 Transformer 的序列建模能力具有重要影响。在三组对比实验中，正弦位置编码取得了最好的整体表现，BLEU 达到 17.13；可学习绝对位置编码的 BLEU 为 15.89，说明模型也可以通过训练学习有效的位置表示；而完全去除位置编码后，BLEU 下降到 6.26，并且翻译结果中出现重复、

漏译、语序混乱和语义偏移等问题。这说明自注意力机制本身并不能天然感知词元顺序，位置编码不是简单的附加模块，而是 Transformer 理解自然语言序列结构的重要组成部分。

对于问题（1）复现上，本文采用小规模模型进行复现，模型完整覆盖了 Transformer 的主要组成部分，在验证中也取得了不错的成绩。

6 讨论

虽然本文复现的 Transformer 已经能够完成英德翻译任务，但实验结果也暴露出一些问题。经典 Transformer 不包含循环结构和卷积结构，因此模型本身缺少天然的序列顺序建模能力。原论文指出，为了使模型能够利用词元顺序，需要在编码器和解码器底部向词嵌入中加入位置编码，并将二者直接相加。

然而，原始位置编码采用统一的加法融合方式，即每个位置的词嵌入都按照相同规则加入位置编码。这种方式简单有效，但没有在输入层显式区分不同词元对位置信息的依赖程度。本文实验中也观察到，在长句翻译中模型仍可能出现漏译、重复生成和局部语序混乱；而完全去除位置编码后，模型对词序的处理能力明显下降。这说明位置编码仍然存在进一步改进的空间。

基于此，本文提出一种可尝试的轻量级改进方向，即让位置编码强度自适应调节。具体来说，可以在词嵌入与位置编码相加之前引入一个门控系数，使模型自动学习当前位置应注入多少位置信息：

$$\mathbf{x}_t = \mathbf{e}_t + \mathbf{g}_t \cdot \mathbf{p}_t$$

其中， $\mathbf{e}_t$ 表示第 t 个词元的词嵌入， $\mathbf{p}_t$ 表示对应的位置编码， $\mathbf{g}_t \in [0, 1]$ 为模型学习得到的位置门控系数。当 $\mathbf{g}_t$ 较大时，模型更强调当前位置的顺序信息；当 $\mathbf{g}_t$ 较小时，模型则相对减弱位置编码对词元语义表示的影响。该方法在 $\mathbf{g}_t = 1$ 时可退化为经典 Transformer 的位置编码形式，因此不会破坏原有模型结构。

这个方法无需改动多头注意力、前馈网络或解码策略等，实现起来较为简单，而且还也可以通过分析门控系数分布，进一步观察不同词元或不同位置对位置信息的依赖差异。

参考文献

- [1] A. Vaswani *et al.*, “Attention Is All You Need,” Aug. 02, 2023, *arXiv*: arXiv:1706.03762. doi: 10.48550/arXiv.1706.03762.